Actividad 1 - Estudio de optimización

Grupo	3-4 personas
Entrega	3/11/2026 (extensión: 9/11/2026)
Valor	15%

La actividad consiste en aplicar los tres últimos algoritmos estudiados en clase (**SARSA, Expected SARSA y Q-Learning**) para resolver un entorno de Gymnasium, analizando cómo afectan al rendimiento tanto la discretización del espacio de observaciones/acciones como el proceso de aprendizaje.

La actividad se divide en dos fases complementarias:

- **Fase A – Optimización de hiperparámetros y presupuestos de discretización:** utilizar Optuna para identificar las mejores configuraciones de cada algoritmo con tres presupuestos diferentes de discretización.
- **Fase B – Análisis del aprendizaje y la convergencia:** realizar entrenamientos prolongados con las nueve configuraciones seleccionadas, analizando sus curvas de aprendizaje, rendimiento, estabilidad y convergencia.

1. Selección del entorno

Se debe seleccionar un entorno de Gymnasium y utilizar nuestros **DiscretizationWrappers** para adaptar el espacio de observaciones/acciones a los algoritmos tabulares.

Posibles opciones:

- Classic Control: Acrobot o MountainCarContinuous.
- Box2D: LunarLander.
- MuJoCo: Reacher, Hopper, Swimmer, Inverted Pendulum o Inverted Double Pendulum.

- Otro entorno compatible con los tres algoritmos utilizando los `DiscretizationWrappers`, previa consulta con el profesor.

2. Fase A – Optimización de hiperparámetros y discretización

1. Definir **tres presupuestos de discretización** (bajo, medio y alto), que produzcan espacios de estados/acciones de tamaños claramente diferentes, usando nuestros `DiscretizationWrappers`.
2. Crear scripts basados en Optuna (similares a `experiment_2.10.py`) para explorar y encontrar configuraciones prometedoras de hiperparámetros para los tres algoritmos (SARSA, Expected SARSA y Q-Learning), utilizando cada uno de los tres presupuestos de discretización (un total de nueve combinaciones).
3. Explorar al menos **180 combinaciones de hiperparámetros** (20 por algoritmo y presupuesto de discretización), manteniendo el mismo presupuesto de entrenamiento durante los experimentos.
4. Seleccionar la mejor combinación de hiperparámetros para cada algoritmo y presupuesto de discretización, obteniendo un total de **nueve configuraciones**.
5. Analizar cómo afecta el presupuesto de discretización al rendimiento obtenido por cada algoritmo.

3. Fase B – Análisis del aprendizaje y la convergencia

1. Diseñar un mecanismo básico para **guardar/cargar la tabla Q** como archivo.
2. Realizar entrenamientos largos utilizando las **nueve configuraciones seleccionadas en la Fase A**, ejecutando al menos **tres entrenamientos independientes por configuración** con diferentes semillas aleatorias (un mínimo de 27 entrenamientos en total).
    - Mantener el mismo presupuesto máximo de entrenamiento para todas las configuraciones, medido en pasos de interacción con el entorno.
    - Registrar en TensorBoard la evolución del proceso de entrenamiento.

3. Guardar cada tabla Q resultante (acompañada de a qué algoritmo y tamaño de discretización pertenece). Evaluar cada una 50 episodios y seleccionar la mejor por cada tamaño de discretización (total: 3).
4. **Realizar una inspección visual del comportamiento de estas 3 políticas finales**.
5. Analizar y comparar los resultados finales considerando, al menos:
    - **Velocidad de aprendizaje:** rapidez con la que los algoritmos mejoran su rendimiento.
    - **Estabilidad:** variabilidad entre las diferentes semillas y oscilaciones durante el aprendizaje.
    - **Convergencia:** si las curvas de aprendizaje muestran una tendencia a estabilizarse y aproximadamente cuánto entrenamiento necesitan para ello.
    - **Influencia de la discretización:** cómo afecta el tamaño del espacio de estados/acciones al comportamiento de cada algoritmo.
    - **Rendimiento final:** resultados de la evaluación de las 3 políticas finales, tanto en términos de recompensa como del comportamiento observado visualmente.

4. Planificación

Se proponen dos posibles estrategias de organización del trabajo:

1. Secuencial: un subgrupo lleva a cabo la Fase A al completo y luego otro subgrupo parte desde los resultados para desarrollar la Fase B. En este caso, hay que tener mucho cuidado con los tiempos, porque hasta que el subgrupo A no termine, el B no puede empezar.
2. Paralelo: las personas se reparten los estudios de Optuna de la Fase A para trabajar en paralelo y posteriormente los entrenamientos largos de la Fase B para trabajar en paralelo.

Independientemente de la estrategia seleccionada, todos los miembros deberán participar en las conclusiones finales.

5. Informe de experimentación

Elaborar un informe (preferiblemente PDF) que contenga, como mínimo, los siguientes apartados:

1. **Portada:** nombres y direcciones de correo electrónico de los estudiantes.
2. **Entorno seleccionado:** descripción y justificación de la elección.
3. **Fase A:**
    a. **Tamaños de discretización:** descripción de los tres niveles utilizados, tamaño de los espacios de estados/acciones, y justificación de los mismos.
    b. **Hiperparámetros:** tabla con los hiperparámetros explorados mediante Optuna y sus correspondientes rangos de búsqueda.
    c. **Resultados de Optuna:** selección de las 3–5 gráficas más relevantes, acompañadas de su interpretación y análisis.
    d. **Mejores configuraciones:** tabla con las nueve configuraciones seleccionadas (una por algoritmo y presupuesto de discretización).
4. **Fase B:**
    a. **Código de serialización:** incluir las funciones Python para guardar y cargar la tabla Q.
    b. **Curvas de aprendizaje:** gráficas de TensorBoard correspondientes a los entrenamientos largos, incluyendo medias y dispersión de las semillas. Comparación e interpretación de los resultados.
    c. **Políticas finales**: tabla comparativa con los resultados de evaluación de las tres políticas finales y breve descripción del comportamiento observado durante su inspección visual.
    d. **Análisis comparativo:** discusión sobre la velocidad de aprendizaje, rendimiento final, estabilidad, convergencia y efecto de los diferentes presupuestos de discretización para los diferentes algoritmos.
5. **Contribuciones individuales:** por cada estudiante indicar su participación en la Fase A y/o B, y una breve descripción (por ejemplo, 1–2 párrafos) de sus funciones, actividades y responsabilidades. Los estudiantes podrán obtener calificaciones individuales diferentes en función de la calidad y el alcance de sus contribuciones.

6. **Conclusiones:** ¿Qué habéis aprendido de los experimentos? ¿Qué diferencias habéis encontrado entre algoritmos y discretizaciones? ¿Qué resultados os han sorprendido?
7. **Otros comentarios:** cualquier otra observación o información que consideréis relevante.

6. Entrega

Subir a la plataforma de la asignatura un archivo ZIP que contenga:

- Informe de experimentación en PDF.
- Scripts de Python utilizados.
- Base de datos de Optuna.
- Registros de TensorBoard de los entrenamientos largos.
- Tres políticas finales tras los entrenamientos largos.

7. Criterios de evaluación

- **[3%] Entorno y tarea**: se valorará según su dificultad y complejidad (ej. tamaño del espacio de observación).
- **[2%] Calidad global del informe**: se valorará la organización y claridad del documento, la calidad de las tablas y figuras, la presentación de los resultados, la integración de ambas fases y la coherencia de las conclusiones.
- **[5%] Fase A** – Optimización de hiperparámetros y discretización: se valorará la selección y justificación de los presupuestos de discretización, la metodología de optimización con Optuna, la calidad de los experimentos y el análisis e interpretación de los resultados.
- **[5%] Fase B** – Análisis del aprendizaje y la convergencia: se valorará el rigor de los experimentos con múltiples semillas, la interpretación de las curvas de aprendizaje, el análisis comparativo del rendimiento, la estabilidad y la convergencia, así como las conclusiones obtenidas.